

RELATÓRIO DE DESENVOLVIMENTO DO MVP: PIPELINE DE DADOS NA NUVEM

Análise de Pedidos da Olist Store (2016–2018)

1. Contexto de Negócios e Formulação do Problema

1.1. Contexto de Negócios

A **Olist Store** é uma startup brasileira que atua no setor de tecnologia (e-commerce) para o varejo. A empresa oferece soluções que conectam pequenos/médios lojistas (vendedores) e grandes marcas a marketplaces, facilitando a gestão de lojas físicas e online, logística e serviços financeiros.

O conjunto de dados utilizado compreende informações de aproximadamente **100 mil pedidos** realizados na Olist Store entre **2016 e 2018**. Trata-se de dados comerciais reais anonimizados disponibilizados publicamente no Kaggle.

Necessidade do Negócio: Buscaremos identificar gargalos na jornada do cliente, entender a dinâmica financeira dos pagamentos e otimizar a distribuição geográfica da malha de vendedores. Atualmente, os dados brutos estão dispersos em múltiplos arquivos, sem modelagem analítica unificada. Para resolver essa limitação, este trabalho constrói um pipeline de dados analítico de ponta a ponta na plataforma **Databricks**, utilizando a **Arquitetura Medalhão (Bronze, Silver e Gold)** e **Unity Catalog**, culminando na construção de uma modelagem dimensional (*Star Schema*).

1.2. Perguntas de Negócio

Para nortear toda a arquitetura técnica, modelagem de dados e validações do pipeline, o trabalho responderá diretamente às seguintes perguntas estratégicas, divididas por domínio de negócio:

1.2.1. Domínio de Finanças e Meios de Pagamento

Pergunta 1: Qual é o ticket médio das transações por método de pagamento (cartão de crédito, boleto, voucher, cartão de débito)?

Pergunta 2: Qual meio de pagamento concentra o maior volume financeiro total e qual apresenta o maior número médio de parcelas?

Objetivo de Análise: Mapear o perfil de pagamento dos clientes para otimizar taxas operacionais e estratégias de liquidez.

1.2.2. Domínio de Logística e Experiência do Cliente

Pergunta 1: Qual é o tempo médio de entrega (em dias corridos desde a compra até a entrega efetiva) agrupado por estado de destino do cliente?

Pergunta 2: Quais são os 5 estados com os maiores índices de atraso na entrega (percentual de pedidos entregues após a data estimada de entrega)?

Objetivo de Análise: Mapear a eficiência da malha logística nacional, identificar estados críticos e fundamentar renegociações de prazos com transportadoras regionais.

1.2.3. Domínio de Desempenho Comercial e Cobertura de Vendedores

Pergunta 1: Qual é a distribuição geográfica dos vendedores em termos de densidade e receita gerada?

Pergunta 2: Quais estados apresentam maior volume de vendas em valor e itens comercializados, e qual a participação percentual dos vendedores locais no atendimento dessas demandas?

Objetivo de Análise: Mapear a concentração da oferta de produtos e direcionar os times de expansão comercial para a prospecção de novos vendedores em regiões de alta demanda e pouca oferta local.

1.3. Especificação do Conjunto de Dados Brutos e Licenciamento

Fonte de Origem: Repositório Público Kaggle (*E-Commerce Public Dataset by Olist*).

Licença de Uso: **CC BY-NC-SA 4.0** (Permite uso educacional e não comercial com a devida atribuição de autoria).

Estrutura de Arquivos Brutos: uso de 6 tabelas relacionais, discriminadas abaixo, em formato CSV conectadas por chaves primárias e estrangeiras (order_id, customer_id, product_id, seller_id):

Tabela	Função no Pipeline	Atributos Principais	Chaves de Relacionamento
olist_orders_dataset	Informações dos Pedidos (Entidade Central)	order_status order_purchase_timestamp order_delivered_customer_date order_estimated_delivery_date	order_id (PK) customer_id (FK)
olist_customers_dataset	Cadastro de Clientes	customer_zip_code_prefix customer_city customer_state	customer_id (PK)
olist_order_items_dataset	Detalhamento dos Itens do Pedido	order_item_id price freight_value shipping_limit_date	order_id (FK) product_id (FK) seller_id (FK)
olist_order_payments_dataset	Transações Financeiras	payment_sequential payment_type payment_installments payment_value	order_id (FK)
olist_products_dataset	Catálogo de Produtos	product_category_name product_weight_g product_length_cm	product_id (PK)
olist_sellers_dataset	Cadastro de Vendedores	seller_city seller_state	seller_id (PK)


2. Ingestão e Carga dos Dados Brutos

2.1. Estratégia de Ingestão

Para simular um ambiente de nuvem corporativo e escalável, a ingestão foi projetada em lote (*batch*). Os arquivos originais foram centralizados na nuvem no ambiente Databricks Unity Catalog Volumes.

2.2. Procedimento Operacional da Carga

1. **Download Local:** Extração dos 6 arquivos CSV originais do Kaggle.
2. **Upload para a Nuvem:** Utilizou-se a interface web do Databricks: New → Add or upload data → Upload files to a volume → Seleção do Schema e Volume no Unity Catalog.
3. **Persistência Inicial:** Os arquivos brutos ficaram armazenados de forma imutável no diretório de volume para posterior leitura pela camada Bronze.



3. Arquitetura do Pipeline de Dados e Processamento Bronze

3.1. Organização do Pipeline

O pipeline ETL foi ramificado em três notebooks encadeados para assegurar modularidade, fácil manutenção e separação das camadas da Arquitetura Medalhão:

01_ingestao_bronze: Leitura dos arquivos CSV brutos e gravação no formato Delta Lake.

02_ingestao_silver: Limpeza, tratamento de tipo, padronização textual e criação das entidades limpas.

03_ingestao_gold: Construção da Tabela Fato unificada e Tabelas Agregadas para resposta direta às perguntas de negócio.


3.2. Camada Bronze (01_ingestao_bronze)

A camada Bronze armazena os dados no formato otimizado Delta Lake mantendo a granularidade original sem alterações de regras de negócio. Foram adicionados metadados para auditoria de pipeline:

_ingestion_time: Timestamp da data e hora da gravação no Data Lake (`current_timestamp()`).

_source_file: Caminho e nome do arquivo de origem.

O Notebook Python **01_ingestao_bronze**, anexado no Github em https://github.com/edsoliveira72/MVP_PUC_Engenharia_Dados/blob/main/01_ingestao_bronze.ipynb faz um processo de ingestão de dados (arquivos CSV para tabelas em formato Delta Lake) dentro do ambiente Databricks, utilizando PySpark e o recurso de Unity Catalog.



```
# Importação de funções nativas do PySpark para manipulação de DataFrames
# current_timestamp: gera a data e hora atuais do momento da execução
# col: permite referenciar colunas específicas do Dataframe (incluindo metadados)
from pyspark.sql.functions import current_timestamp, col

# 1. DEFINIÇÃO DO CAMINHO DE ORIGEM (UNITY CATALOG VOLUMES)
# Define o diretório onde os arquivos CSV brutos estão armazenados
VOLUME_PATH = "/Volumes/workspace/mvp_puc_dados/mvpolist_raw/"

# Executa um comando SQL diretamente na sessão Spark para garantir que o banco de dados/schema existe
# "IF NOT EXISTS" previne que o código falhe caso a base "bronzeolist" já tenha sido criada no Unity Catalog
spark.sql("CREATE DATABASE IF NOT EXISTS bronzeolist")

# 2. Mapeamento de dados (DICIONÁRIO DE/ PARA)
# Estrutura de dados chave-valor associando o nome do arquivo fonte (CSV) ao nome de destino da tabela Bronze
datasets = {
    "olist_customers_dataset.csv": "bronze_customers",
    "olist_orders_dataset.csv": "bronze_orders",
    "olist_order_items_dataset.csv": "bronze_order_items",
    "olist_order_payments_dataset.csv": "bronze_order_payments",
    "olist_products_dataset.csv": "bronze_products",
    "olist_sellers_dataset.csv": "bronze_sellers"
}


# 3. LOOP DE INGESTÃO E TRANSFORMAÇÃO (CSV -> DELTA LAKE)
# Itera sobre cada par (chave, valor) do dicionário
for csv_file, table_name in datasets.items():
    # Interpola o caminho base com o arquivo específico para compor o caminho completo de leitura
    file_full_path = f"{VOLUME_PATH}/{csv_file}"

    print(f"Leendo e processando: {csv_file} -> Tabela: bronzeolist.{table_name}")

    # --- ETAPA 1: LEITURA DO ARQUIVO CSV ---
    # ...
```

Código SQL para inspecionar uma das tabelas criadas:

SELECT * FROM bronze_olist.bronze_orders LIMIT 50;



The screenshot shows a SQL Editor window with a query and its results. The query is: `SELECT * FROM bronze_olist.bronze_orders LIMIT 50;`. The results are displayed in a table with 10 columns: `order_id`, `customer_id`, `order_status`, `order_purchase_timestamp`, `order_approved_at`, `order_delivered_carrier_date`, `order_delivered_customer_date`, and `order_estim`. The table contains 50 rows of data, showing various order details such as IDs, customer IDs, statuses (e.g., delivered, invoiced), and timestamps.

4. Processamento da Camada Silver e Modelagem

4.1. Transformações e Qualidade na Camada Silver (02_ingestao_silver)

Na camada Silver, pegamos os dados brutos salvos no formato Delta da camada Bronze e aplicamos regras de limpeza, padronização e estruturação. O objetivo é deixar os dados prontos para análise e modelagem de negócios na camada Gold, mantendo a granularidade das entidades originais. O processamento da camada Silver foi realizada por meio do Notebook Python **02_ingestao_silver**, anexado no Github em https://github.com/edsoliveira72/MVP_PUC_Engenharia_Dados/blob/main/02_ingestao_silver.ipynb.

As ações executadas visam garantir a conformidade dos dados com os requisitos de qualidade, resolução de valores nulos, ajuste de tipagem e padronização textual:

a) Garantia de Contrato de Dados e Tipagem:

- Métricas de Tempo (Timestamps): Convertem-se todas as colunas de datas da tabela de pedidos (`order_purchase_timestamp`, `order_approved_at`, `order_delivered_customer_date`, etc.) para o tipo nativo `TIMESTAMP`.

- Valores Financeiros e Numéricos: As colunas financeiras (como `price`, `freight_value` e `payment_value`) foram convertidas para `DOUBLE`. Identificadores sequenciais e quantitativos (`payment_installments`, `order_item_id`, dimensões do produto) foram tipados explicitamente como `INTEGER`.

- Identificadores Geográficos: Mantiveram-se os campos de CEP (`zip_code_prefix`) explicitamente tipados como `STRING` em vez de numéricos, prevenindo a perda acidental de zeros à esquerda.

b) Padronização Textual:

Para evitar inconsistências em futuras consultas e agrupamentos (onde "São Paulo" e "sao paulo" seriam tratados como entradas distintas), aplicou-se:

- trim() para remoção de espaços em branco antes e depois das cadeias de caracteres.
- lower() em nomes de cidades e categorias para uniformizar registros em caixa baixa.
- upper() para as siglas de estados (customer_state e seller_state), garantindo a padronização de unidades federativas.


c) Tratamento de Nulos e Enriquecimento (De-Para):

- Na tabela de produtos (silver_products), aplicou-se a função coalesce() para preencher dados ausentes de categorias com valores padrão ("nao_definido"), garantindo que agregações posteriores não ocultem dados por conta de valores NULL.

d) Governança e Rastreabilidade:

- Adicionou-se a coluna de controle _processed_at (current_timestamp()) em todas as tabelas criadas. Esse metadado permite auditar exatamente quando cada registro foi processado e inserido na Camada Silver.

Organização no Unity Catalog: As tabelas resultantes foram consolidadas sob o schema dedicado silver_olist (silver_orders, silver_order_items, silver_customers, silver_sellers, silver_order_payments e silver_products).



Código SQL para inspecionar uma das tabelas criadas:

SELECT * FROM silver_olist.silver_orders LIMIT 50;

	order_id	customer_id	order_status	order_purchase_timestamp	order_approved_at	order_delivered_carrier_date	order_delivered_customer_date	order_estim.
1	e48191c8d54678b7c49138f38d4f7	9e432e6d231297304a76186a10a62d	delivered	2017-10-02T11:07:15.000-00...	2017-10-04T19:55:00.000-00...	2017-10-10T21:25:13.000-00...	2017-10-18T00...	2017-10-18T00...
2	53c0b2f8b37e0d6741a2150273451	b0830b4747afdc620a0b8d802afef	delivered	2018-07-24T20:41:37.000-00...	2018-07-28T03:24:27.000-00...	2018-07-28T14:31:00.000-00...	2018-08-07T15:27:45.000-00...	2018-08-13T00...
3	47770e09100c2d5c44846d9f07e05f	41e2a345d903f0443c3931a1878989	delivered	2018-08-08T08:38:49.000-00...	2018-08-08T08:55:23.000-00...	2018-08-08T13:50:00.000-00...	2018-08-17T18:06:29.000-00...	2018-08-04T00...
4	9480b04a4d95d0e1189c18977b0f0a	681f7f405ea79320eacbaec7375364d2	delivered	2017-11-18T19:28:00.000-00...	2017-11-18T19:45:59.000-00...	2017-11-22T13:38:59.000-00...	2017-12-02T08:38:43.000-00...	2017-12-15T00...
5	a471c129e086a4f3d3a4e4e1f78f199	8a0795a4d4a4a999d0bae4f81ae2d2	delivered	2018-02-13T21:30:29.000-00...	2018-02-14T19:46:34.000-00...	2018-02-14T19:46:34.000-00...	2018-02-18T18:17:02.000-00...	2018-02-28T00...
6	a4191c2d5e1f6d1d4e5c2889c2afec3	502740e7a751c0da7b2b9e9a8960	delivered	2017-07-09T21:57:05.000-00...	2017-07-09T22:10:13.000-00...	2017-07-11T14:58:04.000-00...	2017-07-26T18:57:55.000-00...	2017-08-07T00...
7	136fce7aa04b0b2c49f538a79a098	ae02714b7d4a06a39379699a7b73...	cancelled	2017-04-11T12:22:08.000-00...	2017-04-13T13:25:17.000-00...	NA	NA	2017-05-09T00...
8	6514bda8020c493c2374d6e45783f	9e408b4b3652055269462d37470222	delivered	2017-05-16T13:10:30.000-00...	2017-05-16T13:22:11.000-00...	2017-05-22T10:07:46.000-00...	2017-05-26T12:55:51.000-00...	2017-06-07T00...
9	76c6da6289321a7c938a2b3e4832a33	194a9b0e3515431402b6461e4d1999	delivered	2017-01-23T18:29:09.000-00...	2017-01-23T18:50:47.000-00...	2017-01-26T14:16:31.000-00...	2017-02-02T14:08:10.000-00...	2017-02-06T00...
10	e98b5e8b8e0e0e78585627e16d8f	31e01d163e99624839764d4e4d0c4	delivered	2017-07-29T11:55:02.000-00...	2017-07-29T12:05:32.000-00...	2017-08-10T18:45:24.000-00...	2017-08-16T11:14:30.000-00...	2017-08-23T00...
11	ef0a16c079ec1d09a1da0801a118a6	484a6ed201313c44d7f100959e95c	delivered	2017-05-16T19:50:18.000-00...	2017-05-16T19:50:18.000-00...	2017-05-18T11:40:40.000-00...	2017-05-29T11:18:31.000-00...	2017-06-07T00...
12	34313c0e48a462a55830c089c7e0b	7711c624183d843aaf61855097bc37	delivered	2017-07-13T19:58:11.000-00...	2017-07-13T20:10:08.000-00...	2017-07-14T18:43:29.000-00...	2017-07-19T14:04:48.000-00...	2017-08-08T00...
13	8256da6d0a82b15b6d8e94c8d32918	d3a3e74c768b60314a0c630b17ee2341	delivered	2018-06-07T10:06:18.000-00...	2018-06-09T03:13:12.000-00...	2018-06-11T13:29:00.000-00...	2018-06-19T12:05:52.000-00...	2018-07-18T00...
14	5f996c15d07717a6ed19d77225a30	19402a8f6a60418a0f93348a637f40	delivered	2018-07-23T17:44:10.000-00...	2018-07-23T17:55:14.000-00...	2018-07-23T17:55:14.000-00...	2018-07-20T15:52:25.000-00...	2018-08-08T00...
15	422aaf1d85167c2b8e4e444e4a33c	3a704753d3f1a481884934e6c72a9f	delivered	2018-03-01T15:10:47.000-00...	2018-03-01T15:10:47.000-00...	2018-03-02T12:09:20.000-00...	2018-03-12T23:36:26.000-00...	2018-03-21T00...
16	dcb365111ea0598f9c5d5e0a6d3c	3b682ba309e548942b7a7370a0c	delivered	2018-06-07T19:03:12.000-00...	2018-06-12T23:10:02.000-00...	2018-06-11T14:54:00.000-00...	2018-06-21T15:34:32.000-00...	2018-07-04T00...
17	403e978396a0c4a6223245c310e0cf	738b086f14d6c74b8c5d8e516e3	delivered	2018-01-02T19:00:43.000-00...	2018-01-02T19:09:04.000-00...	2018-01-03T18:19:09.000-00...	2018-01-20T01:38:59.000-00...	2018-02-06T00...
18	1160b09343e4959b6a0f930e0e0cf	31877899e99997626a7a9be4a9b...	delivered	2017-12-28T23:41:31.000-00...	2017-12-28T23:50:22.000-00...	2017-12-29T18:33:05.000-00...	2018-01-08T22:36:36.000-00...	2018-01-29T00...
19	85a49986a4c6a6d7b2b0444e4a4e	089f7c719c7a6c0a677871a0b7	delivered	2017-11-27T03:41:00.000-00...	2017-11-27T03:41:00.000-00...	2017-11-27T03:41:00.000-00...	2017-11-27T03:41:00.000-00...	2017-12-11T00...
20	83018ec11f4e0d841c7d007b4e43f	78db0b2a2c7a07300670c5478b0b	delivered	2017-10-26T15:54:26.000-00...	2017-10-26T16:08:14.000-00...	2017-10-26T21:46:53.000-00...	2017-11-08T22:22:00.000-00...	2017-11-23T00...
21								

4.2. Modelagem Dimensional (Star Schema) e Catálogo de Dados

O modelo analítico foi desenvolvido seguindo o padrão **Star Schema (Esquema Estrela)** para otimizar o desempenho de consultas na camada Gold e alimentar os *Data Marts* operacionais.

A arquitetura orientada ao código PySpark é estruturada a partir da tabela fato central enriquecida **gold_vendas_detalhadas** (que realiza o *join* das entidades da camada Silver), servindo de base para o processamento dos *Data Marts* analíticos específicos de cada domínio.

Nesta camada, a Tabela Fato Agregada (**gold_vendas_detalhadas**) e tabelas agregadas específicas para cada domínio de negócio foram criadas, por meio do Notebook Python **03_ingestao_gold**, anexado no Github em https://github.com/edsoliveira72/MVP_PUC_Engenharia_Dados/blob/main/03_ingestao_gold.ipynb.

- gold_metrics_financeiras;
- gold_metrics_logistica;
- gold_metrics_desempenho_comercial.

```
# 07:28 PM (UTC)

# PIPELINE OLIST - CAMADA GOLD
# Objetivo: Construir tabelas dimensionais, fatos e visões analíticas para
# responder às perguntas estratégicas de Finanças, Logística e Comercial.

from pyspark.sql.functions import col, datediff, when, count, sum as _sum, avg, round, current_timestamp, lit

# 1. Criação do Database Gold
spark.sql("CREATE DATABASE IF NOT EXISTS gold_olist")
print("Database 'gold_olist' criado/verificado com sucesso.")

# TABELA FATO ENRIQUECIDA (BASE PARA OS DATA MARTS)
print("Gerando tabela fato enriquecida: gold_vendas_detalhadas...")

df_pedidos = spark.table("silver_olist.silver_orders")
df_itens = spark.table("silver_olist.silver_order_items")
df_clientes = spark.table("silver_olist.silver_customers")
df_vendedores = spark.table("silver_olist.silver_sellers")


# Join principal entre Pedidos, Itens, Clientes e Vendedores
df_fato_vendas = df_pedidos.join(df_itens, on="order_id", how="inner")
```

Na primeira célula do notebook **03_ingestao_gold** consolidamos o relacionamento dos pedidos com seus itens, clientes, vendedores e pagamentos.

Na segunda célula do notebook **03_ingestao_gold** criamos 3 tabelas de suporte para responder diretamente a cada um dos 3 domínios estabelecidos nas perguntas de negócio (**Finanças e**

Meios de Pagamento, Logística e Experiência do Cliente e Desempenho Comercial e Cobertura de Vendedores).

4.2.1. Esquema Estrela Tabela gold_vendas_detalhadas



gold_vendas_detalhadas

order_id
customer_id
seller_id
product_id
order_status
order_purchase_timestamp
order_approved_at
order_delivered_customer_date
order_estimated_delivery_date
dias_para_entrega
flg_atraso
price
freight_value
valor_total_item
customer_state
customer_city
seller_state
seller_city
flg_venda_local

4.2.2. Catálogo de Dados (Unity Catalog - Schema gold_olist)

4.2.2.1. Tabela Fato Enriquecida: gold_vendas_detalhadas

Contexto: Tabela fato consolidada por item de pedido, contendo métricas calculadas de SLA (Service Level Agreement - Acordo de Nível de Serviço) de entrega e classificação de venda local.

Junção (inner/left) de silver_olist.silver_orders, silver_olist.silver_order_items, silver_olist.silver_customers e silver_olist.silver_sellers.

Campo	Tipo de Dado	Descrição e Regras de Negócio	Domínio / Valores Esperados
order_id	STRING	Identificador único do pedido	Hash UUID de 32 caracteres
customer_id	STRING	Chave de ligação com o cliente	Hash UUID de 32 caracteres
seller_id	STRING	Chave de ligação com o vendedor	Hash UUID de 32 caracteres
product_id	STRING	Chave de ligação com o produto	Hash UUID de 32 caracteres
order_status	STRING	Status atual do processamento do pedido	delivered, shipped, canceled, invoiced, etc.
order_purchase_timestamp	TIMESTAMP	Data e hora em que a compra foi realizada	Formato YYYY-MM-DD HH:MM:SS
order_approved_at	TIMESTAMP	Data e hora de aprovação do pagamento	Formato YYYY-MM-DD HH:MM:SS
order_delivered_customer_date	TIMESTAMP	Data e hora efetiva da entrega ao cliente	Formato YYYY-MM-DD HH:MM:SS (Pode conter nulos)
order_estimated_delivery_date	TIMESTAMP	Data estimada de entrega informada no checkout	Formato YYYY-MM-DD HH:MM:SS
dias_para_entrega	INTEGER	Cálculo do tempo decorrido: datediff(order_delivered_customer_date, order_purchase_timestamp)	Inteiros > = 0 (em dias corridos)
flg_atraso	INTEGER	Flag indicativo de atraso: when(order_delivered_customer_date > order_estimated_delivery_date, 1) otherwise(0)	0 (Em dia / Antecipado), 1 (Com atraso)
price	DOUBLE	Preço unitário do item comercializado	Mín: R\$ 0,85, Máx: R\$ 6.729,00
freight_value	DOUBLE	Valor do frete atribuído ao item	Mín: R\$ 0,00, Máx: R\$ 409,68
valor_total_item	DOUBLE	Soma do preço e frete: (price + freight_value)	Valores numéricos decimais em Reais (R\$)
customer_state	STRING	Sigla do estado do cliente comprador	27 UFs do Brasil (SP, RJ, MG, etc.)
customer_city	STRING	Nome padronizado da cidade do cliente	Nomes de municípios em caixa baixa
seller_state	STRING	Sigla do estado do vendedor	27 UFs do Brasil (SP, PR, SC, etc.)
seller_city	STRING	Nome padronizado da cidade do vendedor	Nomes de municípios em caixa baixa
flg_venda_local	INTEGER	Flag de atendimento regional: when(customer_state == seller_state, 1) otherwise(0)	0 (Venda interestadual), 1 (Venda intraestadual)

4.2.2.2. Data Mart: gold_metrics_financas

Contexto: Tabela analítica agregada por modalidade de pagamento para avaliação de desempenho financeiro e perfil de parcelamento.

Agregação da tabela silver_olist.silver_order_payments.

Campo	Tipo de Dado	Descrição e Regras de Negócio	Domínio / Valores Esperados
payment_type	STRING	Método de pagamento utilizado no pedido	credit_card, boleto, voucher, debit_card
ticket_medio_pagamento	DOUBLE	Média do valor transacionado: round(avg(payment_value), 2)	Valores numéricos decimais em Reais (R\$)
receita_total_pagamento	DOUBLE	Soma do volume transacionado: round(sum(payment_value), 2)	Valores numéricos decimais em Reais (R\$)
total_transacoes	LONG	Volume total de transações processadas: count(order_id)	Números inteiros >= 0
media_parcelas	DOUBLE	Média de parcelas escolhidas: round(avg(payment_installments), 2)	Mín: 1, Máx: 24

4.2.2.3. Data Mart: gold_metrics_logistica

Contexto: Tabela analítica de acompanhamento do nível de serviço (SLA) de entregas agrupada por estado do cliente.

Agregação da tabela gold_olist.gold_vendas_detalhadas filtrando apenas order_status == 'delivered'.

Campo	Tipo de Dado	Descrição e Regras de Negócio	Domínio / Valores Esperados
customer_state	STRING	Estado de destino do comprador (UF)	27 UFs brasileiras
tempo_medio_entrega_dias	DOUBLE	Média em dias para a entrega: round(avg(dias_para_entrega), 2)	Valores decimais em dias corridos
total_pedidos_entregues	LONG	Contagem de pedidos com status entregue: count(order_id)	Números inteiros >= 0
total_pedidos_atrasados	LONG	Quantidade de pedidos entregues após a data estimada: sum(flgs_atraso)	Números inteiros >= 0
pct_pedidos_atrasados	DOUBLE	Percentual de inadimplência no SLA: round((sum(flgs_atraso) / count(order_id)) * 100, 2)	Percentual entre 0,00% e 100,00%

4.2.2.4. Data Mart: gold_metrics_desempenho_comercial

Contexto: Tabela analítica de volumetria comercial e medição da cobertura e dependência da malha de vendedores por estado.

Agregação da tabela gold_olist.gold_vendas_detalhadas agrupando por customer_state.

Campo	Tipo de Dado	Descrição e Regras de Negócio	Domínio / Valores Esperados
customer_state	STRING	Estado consumidor analisado (UF)	27 UFs brasileiras
total_itens_comercializados	LONG	Contagem total de itens vendidos para o estado: count(order_id)	Números inteiros >= 0
receita_total_estado	DOUBLE	Soma do valor total dos itens (preço + frete): round(sum(valor_total_item), 2)	Valores numéricos decimais em Reais (R\$)
qtd_itens_vendedor_local	LONG	Volume de itens vendidos por vendedores da mesma UF: sum(flag_venda_local)	Números inteiros >= 0
pct_participacao_vendedor_local	DOUBLE	Taxa de autossuficiência comercial do estado: round(sum(flag_venda_local) / count(order_id)) * 100, 2)	Percentual entre 0,00% e 100,00%

5. Qualidade de Dados

A avaliação da qualidade de dados no pipeline abordou as 5 dimensões essenciais para garantir dados confiáveis no ambiente produtivo:



5.1. Completeness:

Problema Identificado: Na tabela bruta de produtos (olist_products_dataset), 610 registros apresentavam valor nulo (NULL) para a categoria do produto.

Solução Aplicada: Aplicação da função coalesce(product_category_name, 'nao_definido') na camada Silver, impedindo a perda de dados em agrupamentos analíticos.

5.2. Consistency:

Problema Identificado: Inconsistência de maiúsculas/minúsculas e espaços em branco em nomes de cidades e estados (ex: "Sao Paulo ", "sp").

Solução Aplicada: Limpeza textual padronizada com trim(), lower() para cidades/categorias e upper() para siglas de estados.

5.3. Uniqueness:

Problema Identificado: Risco de duplicação de pagamentos e registros de transação.

Solução Aplicada: Validação de unicidade das chaves primárias (order_id, product_id, customer_id, seller_id) antes das junções relacionais para criação da Tabela Fato Gold.

5.4. Acurácia e Outliers:

Problema Identificado: Prazos de entrega negativos resultantes de inconsistências no registro de sistema e entregas com discrepâncias extremas de datas (>200 dias).

Solução Aplicada: Filtragem explícita na camada Gold desconsiderando entregas com tempo_entrega_dias < 0. Os prazos extremamente longos para regiões remotas foram mantidos por representarem a realidade operacional do transporte rodoviário nacional.

6. Resultados, Validação e Análise de Dados por Domínio

6.1. Domínio de Finanças e Meios de Pagamento - Tabela de Resultados (gold_metrics_financas)

Home

Workspace

Recents

Catalog

Jobs & Pipelines

Compute

Discover

Marketplace

SQL

SQL Editor

Queries

Dashboards

Genie Agents

Alerts

Query History

SQL Warehouses

Data Engineering

Runs

Data Ingestion

Visual Data Prep

AI/ML

Playground

Agents

AI Gateway

Run all (1000)

1 min 44 s ago

workspace: bronze_olot

Respostas de Logística e Experiência do Cliente

Respostas de Desempenho Comercial e Cobrança

SQL

1

2

3

4

5

6

7

8

9

10

11

12

13

14

15

16

17

18

19

20

21

22

23

24

25

26

27

28

29

30

31

32

33

34

35

36

37

38

39

40

41

42

43

44

45

46

47

48

49

50

51

52

53

54

55

56

57

58

59

60

61

62

63

64

65

66

67

68

69

70

71

72

73

74

75

76

77

78

79

80

81

82

83

84

85

86

87

88

89

90

91

92

93

94

95

96

97

98

99

100

101

102

103

104

105

106

107

108

109

110

111

112

113

114

115

116

117

118

119

120

121

122

123

124

125

126

127

128

129

130

131

132

133

134

135

136

137

138

139

140

141

142

143

144

145

146

147

148

149

150

151

152

153

154

155

156

157

158

159

160

161

162

163

164

165

166

167

168

169

170

171

172

173

174

175

176

177

178

179

180

181

182

183

184

185

186

187

188

189

190

191

192

193

194

195

196

197

198

199

200

201

202

203

204

205

206

207

208

209

210

211

212

213

214

215

216

217

218

219

220

221

222

223

224

225

226

227

228

229

230

231

232

233

234

235

236

237

238

239

240

241

242

243

244

245

246

247

248

249

250

251

252

253

254

255

256

257

258

259

260

261

262

263

264

265

266

267

268

269

270

271

272

273

274

275

276

277

278

279

280

281

282

283

284

285

286

287

288

289

290

291

292

293

294

295

296

297

298

299

300

301

302

303

304

305

306

307

308

309

310

311

312

313

314

315

316

317

318

319

320

321

322

323

324

325

326

327

328

329

330

331

332

333

334

335

336

337

338

339

340

341

342

343

344

345

346

347

348

349

350

351

352

353

354

355

356

357

358

359

360

361

362

363

364

365

366

367

368

369

370

371

372

373

374

375

376

377

378

379

380

381

382

383

384

385

386

387

388

389

390

391

392

393

394

395

396

397

398

399

400

401

402

403

404

405

406

407

408

409

410

411

412

413

414

415

416

417

418

419

420

421

422

423

424

425

426

427

428

429

430

431

432

433

434

435

436

437

438

439

440

441

442

443

444

445

446

447

448

449

450

451

452

453

454

455

456

457

458

459

460

461

462

463

464

465

466

467

468

469

470

471

472

473

474

475

476

477

478

479

480

481

482

483

484

485

486

487

488

489

490

491

492

493

494

495

496

497

498

499

500

501

502

503

504

505

506

507

508

509

510

511

512

513

514

515

516

517

518

519

520

521

522

523

524

525

526

527

528

529

530

531

532

533

534

535

536

537

538

539

540

541

542

543

544

545

546

547

548

549

550

551

552

553

554

555

556

557

558

559

560

561

562

563

564

565

566

567

568

569

570

571

572

573

574

575

576

577

578

579

580

581

582

583

584

585

586

587

588

589

590

591

592

593

594

595

596

597

598

599

600

601

602

603

604

605

606

607

608

609

610

611

612

613

614

615

616

617

618

619

620

621

622

623

624

625

626

627

628

629

630

631

632

633

634

635

636

637

638

639

640

641

642

643

644

645

646

647

648

649

650

651

652

653

654

655

656

657

658

659

660

661

662

663

664

665

666

667

668

669

670

671

672

673

674

675

676

677

678

679

680

681

682

683

684

685

686

687

688

689

690

691

692

693

694

695

696

697

698

699

700

701

702

703

704

705

706

707

708

709

710

711

712

713

714

715

716

717

718

719

720

721

722

723

724

725

726

727

728

729

730

731

732

733

734

735

736

737

738

739

740

741

742

743

744

745

746

747

748

749

750

751

752

753

754

755

756

757

758

759

760

761

762

763

764

765

766

767

768

769

770

771

772

773

774

775

776

777

778

779

780

781

782

783

784

785

786

787

788

789

790

791

792

793

794

795

796

797

798

799

800

801

802

803

804

805

806

807

808

809

810

811

812

813

814

815

816

817

818

819

820

821

822

823

824

825

826

827

828

829

830

831

832

833

834

835

836

837

838

839

840

841

842

843

844

845

846

847

848

849

850

851

852

853

854

855

856

857

858

859

860

861

862

863

864

865

866

867

868

869

870

871

872

873

874

875

876

877

878

879

880

881

882

883

884

885

886

887

888

889

890

891

892

893

894

895

896

897

898

899

900

901

902

903

904

905

906

907

908

909

910

911

912

913

914

915

916

917

918

919

920

921

922

923

924

925

926

927

928

929

930

931

932

933

934

935

936

937

938

939

940

941

942

943

944

945

946

947

948

949

950

951

952

953

954

955

956

957

958

959

960

961

962

963

964

965

966

967

968

969

970

971

972

973

974

975

976

977

978

979

980

981

982

983

984

985

986

987

988

989

990

991

992

993

994

995

996

997

998

999

1000

Table

Meio de Pagamento

1.2 Ticket Médio (R\$)

1.2 Volume Financeiro Total (R\$)

1.2 Média de Parcelas

1.2 Total de Transações

1

credit_card

163,32

12542084,19

3,51

76795

2

boleto

145,03

2889961,27

1

19784

3

voucher

65,7

379436,67

1

5775

4

debit_card

142,57

217989,79

1

1529

5

not_defined

0

0

1

3

5 rows

1.878s runtime

See performance (1)

Checked for improvements

Refreshed 1m ago

Análise do resultado:

Resposta 1 (Ticket Médio): O cartão de crédito apresenta o maior ticket médio (R\$ 163,14), superando o boleto (R\$ 145,03) e o cartão de débito (R\$ 142,57). O voucher registra o menor ticket médio (R\$ 65,70) por funcionar essencialmente como vale-compras complementar.

Resposta 2 (Volume e Parcelamento): O cartão de crédito concentra 78,3% do volume financeiro total (mais de R\$ 12,5 milhões) e é o único meio com parcelamento ativo (média de 3,51 parcelas). O boleto bancário ocupa o 2º lugar (~18% do faturamento).

Diagnóstico de Negócio: O crédito parcelado é o principal habilitador de conversão do e-commerce. No entanto, a dependência excessiva do cartão gera custos relevantes de taxas de adquirente e antecipação de recebíveis para os lojistas.

6.2. Domínio de Logística e Experiência do Cliente - Tabela dos 5 Estados com Maior Atraso na Entrega (gold_metrics_logistica)

Home

Learn

Workspace

Recent

Catalog

Jobs & Pipelines

Compute

Discover

Marketplace

SQL

SQL Editor

Queries

Dashboards

Genie Agents

Alerts

Query History

SQL Warehouses

Data Engineering

Runs

Data Ingestion

Visual Data Prep

AI/ML

Playground

Agents

AI Gateway

Run all (1000)

workspace: default

Last edit was now

1

2

3

4

5

6

7

8

9

10

11

12

13

14

15

16

17

18

19

20

21

22

23

24

25

26

27

28

29

30

31

32

33

34

35

36

37

38

39

40

41

42

43

44

45

46

47

48

49

50

51

52

53

54

55

56

57

58

59

60

61

62

63

64

65

66

67

68

69

70

71

72

73

74

75

76

77

78

79

80

81

82

83

84

85

86

87

88

89

90

91

92

93

94

95

96

97

98

99

100

101

102

103

104

105

106

107

108

109

110

111

112

113

114

115

116

117

118

119

120

121

122

123

124

125

126

127

128

129

130

131

132

133

134

135

136

137

138

139

140

141

142

143

144

145

146

147

148

149

150

151

152

153

154

155

156

157

158

159

160

161

162

163

164

165

166

167

168

169

170

171

172

173

174

175

176

177

178

179

180

181

182

183

184

185

186

187

188

189

190

191

192

193

194

195

196

197

198

199

200

201

202

203

204

205

206

207

208

209

210

211

212

213

214

215

216

217

218

219

220

221

222

223

224

225

226

227

228

229

230

231

232

233

234

235

236

237

238

239

240

241

242

243

244

245

246

247

248

249

250

251

252

253

254

255

256

257

258

259

260

261

262

263

264

265

266

267

268

269

270

271

272

273

274

275

276

277

278

279

280

281

282

283

284

285

286

287

288

289

290

291

292

293

294

295

296

297

298

299

300

301

302

303

304

305

306

307

308

309

310

311

312

313

314

315

316

317

318

319

320

321

322

323

324

325

326

327

328

329

330

331

332

333

334

335

336

337

338

339

340

341

342

343

344

345

346

347

348

349

350

351

352

353

354

355

356

357

358

359

360

361

362

363

364

365

366

367

368

369

370

371

372

373

374

375

376

377

378

379

380

381

382

383

384

385

386

387

388

389

390

391

392

393

394

395

396

397

398

399

400

401

402

403

404

405

406

407

408

409

410

411

412

413

414

415

416

417

418

419

420

421

422

423

424

425

426

427

428

429

430

431

432

433

434

435

436

437

438

439

440

441

442

443

444

445

446

447

448

449

450

451

452

453

454

455

456

457

458

459

460

461

462

463

464

465

466

467

468

469

470

471

472

473

474

475

476

477

478

479

480

481

482

483

484

485

486

487

488

489

490

491

492

493

494

495

496

497

498

499

500

501

502

503

504

505

506

507

508

509

510

511

512

513

514

515

516

517

518

519

520

521

522

523

524

525

526

527

528

529

530

531

532

533

534

535

536

537

538

539

540

541

542

543

544

545

546

547

548

549

550

551

552

553

554

555

556

557

558

559

560

561

562

563

564

565

566

567

568

569

570

571

572

573

574

575

576

577

578

579

580

581

582

583

584

585

586

587

588

589

590

591

592

593

594

595

596

597

598

599

600

601

602

603

604

605

606

607

608

609

610

611

612

613

614

615

616

617

618

619

620

621

622

623

624

625

626

627

628

629

630

631

632

633

634

635

636

637

638

639

640

641

642

643

644

645

646

647

648

649

650

651

652

653

654

655

656

657

658

659

660

661

662

663

664

665

666

667

668

669

670

671

672

673

674

675

676

677

678

679

680

681

682

683

684

685

686

687

688

689

690

691

692

693

694

695

696

697

698

699

700

701

702

703

704

705

706

707

708

709

710

711

712

713

714

715

716

717

718

719

720

721

722

723

724

725

726

727

728

729

730

731

732

733

734

735

736

737

738

739

740

741

742

743

744

745

746

747

748

749

750

751

752

753

754

755

756

757

758

759

760

761

762

763

764

765

766

767

768

769

770

771

772

773

774

775

776

777

778

779

780

781

782

783

784

785

786

787

788

789

790

791

792

793

794

795

796

797

798

799

800

801

802

803

804

805

806

807

808

809

810

811

812

813

814

815

816

817

818

819

820

821

822

823

824

825

826

827

828

829

830

831

832

833

834

835

836

837

838

839

840

841

842

843

844

845

846

847

848

849

850

851

852

853

854

855

856

857

858

859

860

861

862

863

864

865

866

867

868

869

870

871

872

873

874

875

876

877

878

879

880

881

882

883

884

885

886

887

888

889

890

891

892

893

894

895

896

897

898

899

900

901

902

903

904

905

906

907

908

909

910

911

912

913

914

915

916

917

918

919

920

921

922

923

924

925

926

927

928

929

930

931

932

933

934

935

936

937

938

939

940

941

942

943

944

945

946

947

948

949

950

951

952

953

954

955

956

957

958

959

960

961

962

963

964

965

966

967

968

969

970

971

972

973

974

975

976

977

978

979

980

981

982

983

984

985

986

987

988

989

990

991

992

993

994

995

996

997

998

999

1000

Table

1.2 Estado de Destino

1.2 Tempo Médio de Entrega (dias)

1.2 Índice de Atraso (%)

1.2 total_pedidos_entregues

1.2 total_pedidos_atrasados

1

2

3

4

5

6

7

8

9

10

11

12

13

14

15

16

17

18

19

20

21

22

23

24

25

26

27

28

29

30

31

32

33

34

35

36

37

38

39

40

41

42

43

44

45

46

47

48

49

50

51

52

53

54

55

56

57

58

59

60

61

62

63

64

65

66

67

68

69

70

71

72

73

74

75

76

77

78

79

80

81

82

83

84

85

86

87

88

89

90

91

92

93

94

95

96

97

98

99

100

101

102

103

104

105

106

107

108

109

110

111

112

113

114

115

116

117

118

119

120

121

122

123

124

125

126

127

128

129

130

131

132

133

134

135

136

137

138

139

140

141

142

143

144

145

146

147

148

149

150

151

152

153

154

155

156

157

158

159

160

161

162

163

164

165

166

167

168

169

170

171

172

173

174

175

176

177

178

179

180

181

182

183

184

185

186

187

188

189

190

191

192

193

194

195

196

197

198

199

200

201

202

203

204

205

206

207

208

209

210

211

212

213

214

215

216

217

218

219

220

221

222

223

224

225

226

227

228

229

230

231

232

233

234

235

236

237

238

239

240

241

242

243

244

245

246

247

248

249

250

251

252

253

254

255

256

257

258

259

260

261

262

263

264

265

266

267

268

269

270

271

272

273

274

275

276

277

278

279

280

281

282

283

284

285

286

287

288

289

290

291

292

293

294

295

296

297

298

299

300

301

302

303

304

305

306

307

308

309

310

311

312

313

314

315

316

317

318

319

320

321

322

323

324

325

326

327

328

329

330

331

332

333

334

335

336

337

338

339

340

341

342

343

344

345

346

347

348

349

350

351

352

353

354

355

356

357

358

359

360

361

362

363

364

365

366

367

368

369

370

371

372

373

374

375

376

377

378

379

380

381

382

383

384

385

386

387

388

389

390

391

392

393

394

395

396

397

398

399

400

401

402

403

404

405

406

407

408

409

410

411

412

413

414

415

416

417

418

419

420

421

422

423

424

425

426

427

428

429

430

431

432

433

434

435

436

437

438

439

440

441

442

443

444

445

446

447

448

449

450

451

452

453

454

455

456

457

458

459

460

461

462

463

464

465

466

467

468

469

470

471

472

473

474

475

476

477

478

479

480

481

482

483

484

485

486

487

488

489

490

491

492

493

494

495

496

497

498

499

500

501

502

503

504

505

506

507

508

509

510

511

512

513

514

515

516

517

518

519

520

521

522

523

524

525

526

6.3. Domínio de Desempenho Comercial e Cobertura de Vendedores - Tabela de Atendimento Comercial por Estado (gold_metrics_desempenho_comercial)

SQL Editor

```
-- Pergunta 1 e 2: Vendas por estado do cliente e % de participação de vendedores locais
SELECT
  customer_state AS "Estado Consumidor",
  receita_total_estado AS "Receita Total Consumida (R$)",
  total_itens_comercializados AS "Total Itens Adquiridos",
  pct_participacao_vendedor_local AS "Venda Local (% Atendida na UF)"
FROM gold_metrics_desempenho_comercial
ORDER BY receita_total_estado DESC;
```

	1. Estado Consumidor	1.2 Receita Total Consumida (R\$)	2. Total Itens Adquiridos	1.2 Venda Local (% Atendida na UF)
1	SP	5921678.12	47449	76,28
2	RJ	2129681.98	14379	7,7
3	MG	1856161.49	13129	13,02
4	RS	885826.76	6235	5,24
5	PR	800935.44	5740	14,41
6	BA	611506.67	3799	2,05
7	SC	490215.6	4376	7,45
8	DF	393229.44	2406	2,54
9	GO	347706.92	2322	1,67
10	ES	324801.91	2256	0,4
11	PE	322237.69	1806	1,33
12	CE	275606.3	1478	0,61
13	PA	217647.11	1080	0
14	MT	186168.96	1055	0,66
15	MA	151171.99	824	1,82

Análise do resultado:

Resposta 1 (Distribuição de Vendedores): Há uma altíssima concentração de oferta no Eixo Sul-Sudeste: mais de 70% da base ativa de vendedores está sediada no estado de São Paulo.

Resposta 2 (Volume e Venda Local): São Paulo é o maior mercado consumidor (R\$ 5,92 mi) e consegue suprir 76,28% de sua própria demanda com vendedores locais. Em contrapartida, estados com alto volume de compras como Rio de Janeiro (R\$ 2,12 mi) e Minas Gerais (R\$ 1,85 mi) dependem de vendedores externos para suprir 92,3% e 86,98% de suas demandas, respectivamente. No Nordeste, a taxa de atendimento local é inferior a 3%.

Diagnóstico de Negócio: A concentração da oferta em São Paulo é a causa raiz direta das falhas logísticas identificadas no Domínio 2. Como quase todas as mercadorias saem de SP com destino a outros estados, as distâncias percorridas encarecem o frete e multiplicam os prazos de transporte.

6.4. Conclusão Integrada

O desequilíbrio na distribuição de vendedores obriga mercadorias a atravessarem o país a partir de São Paulo para abastecer praças consumidoras relevantes como RJ, MG e a Região Nordeste.

Os custos elevados de frete encarecem o valor final da compra, forçando o cliente a utilizar o parcelamento no cartão de crédito em até 3,5 vezes para diluir os custos operacionais do pedido.

6.5. Recomendações

a) Expansão Comercial Direcionada: Prospector e integrar vendedores locais nos estados do Rio de Janeiro, Minas Gerais e em hubs estratégicos do Nordeste (Ceará/Pernambuco).

b) Rede de Operações Regionais: Implementar centros de distribuição descentralizados no Nordeste para antecipar estoques de alta rotatividade.

c) Estímulo ao PIX/Débito: Conceder descontos progressivos (ex: 3% a 5%) para compras via meios à vista, reduzindo o custo de antecipação e aumentando a margem da plataforma.

7. Autoavaliação do Desenvolvimento

7.1. Atingimento dos Objetivos

Os objetivos propostos para o MVP foram atingidos. O pipeline construído no Databricks processou com êxito os dados brutos da Olist Store, aplicando a Arquitetura Medalhão com Unity Catalog. A Tabela Fato e as Tabelas Agregadas criadas permitiram responder às 6 perguntas estratégicas com base em dados consolidados.

7.2. Dificuldades Encontradas

Aprendizado da biblioteca Pyspark, apesar de ser parecido com a biblioteca Pandas que eu já utilizo em meu trabalho.

Uso do Databricks, pois tive que aprender do zero. Contudo, considero que valeu muito a pena aprender o uso dessa ferramenta.

7.3. Trabalhos Futuros para Aprimoramento do Portfólio

a) Orquestração Automática: Implementar fluxos automatizados de agendamento e dependências via Databricks Workflows.

b) Visualização Interativa: Conectar a Camada Gold a uma ferramenta de BI (Power BI ou Databricks Dashboards) para disponibilização de painéis interativos à liderança executiva.